

原始 Frankenstein-v28 N-甲基化扩展 ProteinMPNN 的单体与复合物评估

Ser 来源修正、六个非 3AV 复合物的预设分析与 17 靶点探索性证据

项目组（作者与单位信息待补）

中文内部审阅稿 v1.0 | 2026年8月21日

冻结对象：未经后续 V7/V8/V9 修改的原始 frankenstein_v28.pt。

SHA-256：bab7b8a010114fc52c749fab1914d9d8ae561ddca45d6d7a0fbec3f9f5ac5b2e

仓库基线：DCarchimonde/proteinmpnn-clean-v28@c9718e2a（完整提交见源清单）。

稿件性质：Task 1 的完整中文解释稿；所有可报告结果、不可报告指标、历史错误口径和数据缺口均在同一文档中列明。

本稿不把预测置信度称为能量，不把肽自对齐 RMSD 称为结合姿态，不把 oracle best-of-N 结果称为无偏生成性能。

摘要

目的: 对未经后续修改的原始 frankenstein_v28.pt 进行一次可追溯的回顾性评价, 并把单体、六个非 3AV 复合物的预设主分析以及 17 靶点的探索性下游结果统一到同一篇中文稿件中。

方法: 模型文件由 SHA-256 冻结。单体留出集含 151 个 Rosetta 理论结构、1505 个真实序列位点; 751 个单体原始 PDB 全部标记为 Rosetta 理论模型, 不存在可核验的“Baker 33 真结构”子集。来源审计发现旧标签中有 62 个 Ser 被错误标为 N-甲基化; 在不改变模型权重与预测概率的前提下, 将评价真值修正为 261 个阳性与 1244 个阴性。甲基化阈值预设严格大于 0.6。复合物主分析仅纳入 1SFI、3P8F、3WNE、3ZGC、4K1E 和 4KEL, 在温度 0.5 下保留至少一个已保存甲基化标记的序列。结构判定要求全复合物 CA 在一次全局对齐后, 复合物全局 CA RMSD 与末链环肽的 best-forward 循环移位 CA RMSD 同时严格低于同一阈值。17 靶点 best85 结果因按天然序列恢复率进行 best-of-N 选择, 仅作探索性支持。

结果: 单体天然化氨基酸恢复率 (RAA) 为 16.08%, 完整扩展 token 恢复率为 14.88%。修正标签后, 已知天然序列甲基分类 AUC 为 0.900, 在阈值 > 0.6 时 Accuracy、Precision、Recall 和 F1 分别为 86.18%、64.02%、46.36% 和 53.78%; 端到端 AUC 为 0.908, 对应四项指标为 89.10%、88.80%、42.53% 和 57.51%。端到端二分类甲基召回为 111/261 (42.53%), 但同时恢复正确天然氨基酸身份和甲基状态的真实甲基残基仅 20/261 (7.66%)。六复合物在温度 0.5 下共有 544 条原始序列, 476 条 (87.50%) 满足甲基化保留门且全部匹配结构 RMSD。联合 RMSD $< 3 \text{ \AA}$ 为 16/476 (3.36%, Wilson 95% CI 2.08–5.39%), $< 5 \text{ \AA}$ 为 101/476 (21.22%, 17.78–25.11%); 以全部 544 条原始序列为分母, 端到端产率分别为 2.94% 和 18.57%。17 靶点 best85 的肽受体框架 CA RMSD 均值/中位数为 29.93/40.06 $\text{\AA}$, 而肽自对齐 CA RMSD 为 2.65/2.53 $\text{\AA}$; 这表明内部形状与结合姿态必须分开解释。其平均结构多样性 $1 - TM$ 为 0.660; 预测通透性、置信度与自然化 fixed-pose Rosetta 分数仅作为描述性证据。

结论: 原始模型在单体甲基化位点排序上具有辨别力, 但在阈值 0.6 下召回率中等, 且基础序列恢复率较低。六复合物的严格端到端产率显示, 主要瓶颈是环肽在同一复合物坐标系中的结合姿态, 而非受体/全局对齐本身。当前证据支持把本结果作为模型能力边界与下一轮改进基线, 而不支持宣称已实现高成功率结构设计。单体结构 RMSD、显式全原子甲基 RMSD、结合位点恢复、相对天然能量成功率与稳定性尚无可核验结果, 未作填补。

关键词: N-甲基化环肽; ProteinMPNN; 序列设计; 甲基化分类; RMSD; 端到端产率; 数据来源审计

读者先看这三句话

1. 正文单体指标使用“去 padding、Ser 来源修正、阈值严格 > 0.6 ”口径; 用户提供的两张旧终端截图只在附录进行错误复盘。
2. 六复合物的 3.36% 与 21.22% 是通过甲基化保留门后的条件比例; 真正从原始 544 条序列出发的产率是 2.94% 与 18.57%。
3. best85 是利用天然序列恢复率选出的 oracle 代表, 不是未知天然序列时可直接获得的部署性能。

目录

摘要	1
1 引言	6
2 材料与方法	6
2.1 模型冻结与可追溯性	6
2.2 单体数据与来源审计	6
2.3 单体序列与甲基化指标	7
2.4 17 个天然复合物与全温度生成池	8
2.5 六个非 3AV 复合物的预设主分析	8
2.6 六复合物 RMSD 的冻结定义	8
2.7 best85 的探索性结构与下游指标	8
2.8 统计与缺失值规则	9
3 结果：单体序列恢复与甲基化分类	9
3.1 Ser 来源修正改变评价真值，但不改变模型输出	9
3.2 两个 Rosetta 来源面板的描述性分层	9
3.3 RAA 与联合扩展 token 恢复率	9
3.4 已知天然序列与端到端甲基化分类	10
3.5 阈值结果的解释边界	11
3.6 原始 V28 没有可报告的单体结构结果	11
4 六个非3AV复合物：温度0.5的预设主分析	12
4.1 从原始生成到可评价队列	12
4.2 RMSD分布与联合结构成功率	12
4.3 甲基化输出的组成	14
4.4 每靶点oracle代表与选择条件化的下游读数	14
5 17 靶点的探索性支持结果	16
5.1 天然复合物集合不能评价甲基阳性召回	16
5.2 五个温度的生成覆盖与重复率	16
5.3 best85：肽内部形状尚可，但结合姿态普遍偏离	18
5.4 多样性、置信度、通透性和 fixed-pose 分数	18
6 讨论	19
6.1 原始模型的能力边界	19
6.2 不同靶点需要不同诊断	19
6.3 数据审计为何改变结论	20
6.4 限制与尚未完成的论文指标	20
6.5 下一步最小充分验证	20
7 结论	20
A 尚哥指标清单的证据可用性矩阵	22
A.1 模型、数据与序列指标	22
A.2 结构、能量、多样性与通透性指标	25
A.3 矩阵所引用的冻结数据资产	28

B 历史截图、旧标签与 padding 错误复盘	28
B.1 两张终端截图为什么不能作为论文主表	28
B.2 去 padding 后, Ser 真值修正仍然必要	29
B.3 规划截图是指标清单, 不是已完成数据	30
C 联合RMSD低于5 Å的101条候选清单	30
D 可复现性、文件索引与使用方法	35
D.1 本稿如何生成	35
D.2 冻结标识与检查项	35
D.3 本地编译	35
D.4 解释规则	36

图目录

1	原始检查点在 Ser 来源修正单体留出集上的甲基化预测表现。A, ROC 曲线; B, 精确率-召回率曲线; C, 不同置信度阈值下的 F1; D, 严格 $p > 0.6$ 时的 Accuracy、Precision、Recall 与 F1。蓝色表示已知天然序列任务, 橙色表示端到端任务。所有曲线和计数均来自1505个真实残基位点, 不含 padding。	11
2	六个非3AV复合物的队列漏斗与RMSD通过率 (Fig. 1)。 (A) 各靶点原始生成及严格 $p > 0.6$ 后保留数量; (B) 各靶点联合RMSD类别; (C) 总体全复合物、环肽以及二者联合的通过率。图中的结构通过率以476条 保留设计为分母; 从544条原始生成开始的端到端产率另见表 5。	13
3	六个非3AV复合物的RMSD分布与关系 (Fig. 2)。全复合物CA RMSD 来自唯一一次全复合物叠合; 循环肽CA RMSD在同一坐标系内采用最佳正向循环 移位计算。虚线标示3 Å与5 Å阈值。	15
4	保留设计的预测甲基化位置与数量 (Fig. 3)。序列中的小写残基表示 原始生成文件按严格 $p > 0.6$ 保存的甲基化预测; 位点编号为设计肽链的1基坐标。	15
5	六条oracle代表的选择条件化下游指标 (Fig. 5)。 (A) 全复合物与 循环肽RMSD; (B) 预测通透性 (log10尺度); (C) 固定构象PyRosetta界面能; (D) 结构文件CA B-factor均值代理量。所有面板均须结合正文的oracle选择警告解释。	17
6	17 靶点 best85 的探索性支持结果。A, 靶点内五温度代表的 1 – TM 分布; B, 按温度分层的通透性预测, 其中3条为相同序列的跨温度回填; C, 自然化 fixed-pose cross-interface Rosetta 分数; D, 各指标的文件可用数。所有面板均受 oracle 选择影响, 不能替代六复合物的预设主分析。	19
7	历史端到端阈值截图。该次运行的有效数组长度为 1947, 其中 442 个为 padding, 故比例不能用于论文。原始图片仅用于审计留档。	28
8	历史二分类阈值截图。该次运行多计入 386 个 padding 阴性; 所有显示值均可由错误混淆矩阵精确重构。	29
9	尚哥提出的数据与指标规划截图。它定义了希望覆盖的项目, 但不等于每项已经有原始结果; 实际可用性逐项列于附录 A。	30

表目录

1	单体数据文件的可核验事实。所有 751 个原始 PDB 均标记为 Rosetta 生成的理论模型; 规划截图中的“Baker 33、Rosetta 400+300”与冻结文件不一致。	7
2	Ser 来源修正后, 单体测试集按 Rosetta 理论结构面板分层的结果。F1 均使用严格 $p > 0.6$ 。	9
3	原始 V28 在 Ser 来源修正单体留出集上的序列级结果。	10
4	Ser 来源修正标签下的单体甲基化分类结果 (严格 $p > 0.6$)。	10
5	六个非3AV复合物的序列漏斗与端到端联合RMSD产率	12
6	保留设计的RMSD分布与联合通过率	14
7	六个靶点按最小循环肽RMSD选择的oracle代表	14
8	17 个天然复合物上的可报告序列指标。所有甲基化真值均为阴性。	16
9	17 靶点原始生成池的温度分层统计。唯一数是在各温度内去重; 甲基标记率为序列内小写甲基 token 比例的均值。	16
10	best85 的旧结构评价。受体框架对齐反映结合姿态; 肽自对齐仅反映内部形状。	18
11	模型、数据与序列指标的队列级可用性。	23
12	结构与下游指标的队列级可用性。	26
13	同一原始检查点在不同评价真值下的单体结果。阈值均为严格 $p > 0.6$; 旧标签只用于敏感性比较。	29
14	六个非 3AV 复合物中联合 RMSD 低于 5 Å 的 101 条候选	31

16	交付目录索引。	35
----	-----------------	----

1 引言

ProteinMPNN 以给定蛋白骨架为条件生成氨基酸序列，原始工作表明其能够处理单链与多链设计问题[1]。本项目在此基础上增加了 N-甲基化表示：先预测天然氨基酸，再由与天然残基类别相对应的甲基化专家头给出位点置信度。因此，模型实际上同时面对两个相互耦合但不等价的问题：

1. **基础序列问题**：给定结构，天然化后的氨基酸是否恢复正确；
2. **甲基化问题**：在已知或模型预测的天然氨基酸条件下，该位点是否应标记为 N-甲基化；
3. **结构问题**：生成序列形成的结构是否保持合理的内部构象，并处于正确的受体结合姿态。

这三类问题不能用一个数字代替。较高的甲基分类 AUC 不等于较高的天然序列恢复率；较低的肽自对齐 RMSD 也不等于正确结合；结构预测文件中的 B-factor/pLDDT 代理值更不是物理能量。为了避免这些概念在先前零散汇报中互相混淆，本研究将所有可追溯证据按数据队列和评价定义重新组织。

本稿只完成 Task 1，研究对象严格冻结为原始 frankenstein_v28.pt。后续 V7、V8、V9 的训练、拼接或稳定性修复不属于本文结果。核心问题包括：

- 原始模型在单体留出集上的 RAA、AUC、Accuracy、Precision、Recall 与 F1 到底是多少；
- 为什么先前截图出现 16.59%、38.11% 与 85.67% 等值，以及它们能否用于论文；
- 在温度 0.5、甲基化置信度严格 > 0.6 的条件下，六个非 3AV 复合物从原始序列到联合 RMSD $< 3 \text{ \AA}$ 或 $< 5 \text{ \AA}$ 的真实产率是多少；
- 17 靶点的 best85 结构、置信度、多样性、通透性与 fixed-pose 能量能说明什么，又不能说明什么；
- 尚哥提出的全部指标中，哪些已经有合格证据，哪些仍未计算或在数学上不可定义。

论文的主张边界是保守且明确的：我们报告已经观测到的模型输出和结构计算结果，但不从预测分数外推实验透膜性、结合自由能或生物活性；不把缺失值填成零；不以选择后的代表样本替代完整生成母。

2 材料与方法

2.1 模型冻结与可追溯性

全文只评价原始检查点 frankenstein_v28.pt，SHA-256 为 bab7b8a010114fc52c749fab1914d9d8ae561ddca45d6d7a0fbec3f9f5ac5b2e。检查点包含 ProteinMPNN 风格的共享结构条件编码/解码主干、20 类天然氨基酸输出头，以及按天然残基类别选择的甲基化专家头。ProteinMPNN 的基本思想与原始实现见 Dauparas 等[1]；本研究所述 N-甲基化扩展与其结果均以项目仓库中的冻结代码、表格和哈希为准。

检查点顶层只保存 model_state_dict，没有 epoch、随机种子、优化器状态、训练数据 manifest 或输入权重哈希。合并脚本的默认参数指向一个 V28 基础模型和一个甲基化专家模型，但没有运行 manifest 能证明最终文件正是由这两个默认路径生成。因此，本文可以冻结并评价最终 checkpoint，却不虚构无法追溯的完整训练谱系，也不宣称相对初始化模型的增益。

本文未为写作重新运行模型、HighFold/ESMFold、TM-align、通透性预测或 PyRosetta。所有数值均从此前已经生成并审计的位点预测表、FASTA、结构匹配表和 RMSD 表中读取。此策略减少了因软件环境、随机种子或上游服务变化而引入的第二套结果。源文件与哈希见 SOURCE_MANIFEST.json。

2.2 单体数据与来源审计

原始历史仓库在冻结提交中保留了 751 条合并单体记录，并以 600/151 划分训练集与测试集。对对应 751 个原始 PDB 的逐文件复核显示：751/751 的 EXPDTA 字段均标为 THEORETICAL MODEL，并且都含有 MODEL GENERATED BY ROSETTA 记录。其中 406 条 Me_ 前缀来自 Rosetta 2023.35+release.23439d3，345 条 pdb_ 前缀来自 Rosetta 2025.25+release.a0cefad01b。因此，这批单体应准确称为两个版本的 Rosetta 理论结构面板，而不是 Baker 实验真结构。现有精确名称与天然化

序列检查没有发现 train-test 完全相同记录，但尚未做同源聚类，因此不能排除较远的同源泄漏。

表 1 单体数据文件的可核验事实。所有 751 个原始 PDB 均标记为 Rosetta 生成的理论模型；规划截图中的“Baker 33、Rosetta 400+300”与冻结文件不一致。

数据对象	总条数	Me_	pdb_	Git blob	本文用途
历史合并集	751	406	345	768d7863ac1a...	Rosetta-2023/2025 理论结构
历史训练集	600	323	277	720b7e65d4bf...	训练来源背景；无完整训练日志
留出测试集	151	83	68	bd18c23881cb...	Rosetta-2023/2025 为83/68 条，共 1505位点
Ser修正测试集	151	83	68	SHA-256 56f877bb9987...	论文主真值

旧测试标签包含 323 个小写甲基化位点，其中 74 个为 Ser。后续来源审计确认 62 个 Ser 应为天然 Ser；修正后为 261 个甲基化阳性、1244 个阴性，甲基化率为 17.34%。模型权重、每个位点预测概率与天然氨基酸目标均未改变，只有评价真值改变。因此，本稿主结果使用修正标签；旧 323 阳性口径仅用于敏感性审计。

751 个 PDB 的文件级来源、Rosetta 版本、训练/测试归属、SHA-256 与 Git blob 逐行列于 data/Monomer_PDB_Provenance_751.csv；扫描程序为 scripts/audit_monomer_pdb_provenance.py。精确名称与天然化序列的 train-test 重叠审计结果位于 data/Monomer_Train_Test_Exact_Overlap_Audit.json，两类交集均为 0；该检查不等价于同源聚类，不能排除较远同源泄漏。

2.3 单体序列与甲基化指标

天然化氨基酸恢复率定义为

$$RAA = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{a}_i = a_i), \quad (1)$$

其中所有小写 N-甲基化 token 在比较前映射回对应大写天然氨基酸。

甲基化二分类采用两种输入条件：

已知天然序列 (known-sequence) 用真实天然氨基酸类别选择相应专家头，隔离甲基化头自身的辨别能力；

端到端 (end-to-end) 先由基础头预测天然氨基酸，再用预测类别选择专家头，包含基础序列错误的级联影响。

二者均在 1505 个真实位点上计算 ROC-AUC、Accuracy、Precision、Recall、F1 与假阳性率。预设甲基化判定为 $p_i > 0.6$ ，等号不通过。尚哥清单中的“RMC”不是统一的标准缩写；若它指不考虑天然氨基酸类别是否正确的甲基阳性二分类恢复率，则其数学定义就是 Recall：

$$\text{Recall} = \frac{TP}{TP + FN}. \quad (2)$$

若“RMC”指“天然氨基酸身份和甲基状态同时正确的真实甲基残基比例”，则应另记为 exact methylated-residue recovery；若以全部位点为分母，则是联合扩展 token recovery。本文并列给出三者的清楚名称和分母，不把它们混成一个 RMC 数字。

2.4 17 个天然复合物与全温度生成池

天然复合物集合含 17 个靶点，共 251 个选中短肽位点。天然序列评价保留每个结构中预先选定的全部短肽链，因此部分靶点贡献多条等价肽链；这与生成结构中每个候选只评价一条预测末链的口径不同。该天然集合没有甲基化阳性标签，因此 AUC、Precision、Recall 与 F1 在数学上不可定义；只能报告基础 RAA、阴性位点上的假阳性率与预测阳性率。

原始生成池覆盖温度 0.01、0.1、0.2、0.3 与 0.5。记录总数、去重数、天然氨基酸恢复和甲基标记率均在每个温度内汇总。此前的 best85 是对每个靶点、每个温度各选一条，共 $17 \times 5 = 85$ 条；选择标准使用了天然序列恢复率，因此属于 **oracle best-of-N**，不能作为未知天然序列时的无偏部署性能。

2.5 六个非 3AV 复合物的预设主分析

主分析只包括 1SFI、3P8F、3WNE、3ZGC、4K1E 和 4KEL，排除全部 3AV 系列。候选只来自主目录温度 $T = 0.5$ 的 FASTA；排除 .ipynb_checkpoints 等重复/缓存目录。原始序列共 544 条。甲基化保留门要求序列至少含一个由原始生成器以严格 $p > 0.6$ 保存的小写标记，得到 476 条。

“有效生成概率”用两个分母同时报告：

$$\text{保留后条件通过率} = \frac{N_{\text{RMSD pass}}}{476}, \quad (3)$$

$$\text{原始端到端产率} = \frac{N_{\text{RMSD pass}}}{544}. \quad (4)$$

前者描述进入结构阶段后的质量，后者回答一次原始生成得到合格候选的概率；二者不可互换。

2.6 六复合物 RMSD 的冻结定义

对每个预测复合物与相应天然复合物仅进行一次全复合物 CA 对齐。随后在同一个变换后的坐标系中计算：

1. **全局复合物 CA RMSD**：使用已审计的复合物匹配 CA 原子；
2. **环肽 CA RMSD**：使用预测和天然结构的完整末链肽 CA，枚举所有正向循环移位并取最小值；
3. 不允许反向序列，不对肽进行第二次自对齐，不丢弃难配对位点；完整位点覆盖是硬质量门。

联合 $< d$ 判定要求全局复合物与环肽 RMSD 均严格小于 d ，其中 $d \in \{3, 5\} \text{ \AA}$ 。循环肽没有唯一的线性起点，因此 best-forward 循环移位是主定义；固定起点结果只作为表示敏感性分析。

2.7 best85 的探索性结构与下游指标

best85 的旧结构分析与六复合物主分析使用不同队列和 RMSD 定义，单独报告：

- **受体框架对齐后肽 RMSD**：先拟合受体 CA，再测肽 CA 或 N/CA/C backbone，反映结合姿态；
- **肽自对齐 RMSD**：单独拟合肽本身，反映内部形状，不反映结合位置；
- **多样性**：同一靶点五个温度代表之间两两比较，共 170 对，使用对称 TM-score 的 $1 - \text{TM}$ ；TM-score 的尺寸归一化思想见 Zhang 与 Skolnick[2]；
- **置信度**：优先区分 PDB CA B-factor 均值代理与 HighFold COMMENT 中的 global/chain pLDDT、pTM、ipTM、PAE 字段。结构预测模型的置信度概念可参照 AlphaFold 与 ESMFold 文献[3, 4]，但本项目字段不应跨实现直接等同；
- **通透性**：只报告外部预测值及其分布，无实验标签；
- **能量**：将非标准甲基残基自然化后，在固定构象上计算 Rosetta 分数。没有 FastRelax、最小化、repacking 或显式 N-甲基参数。单位为 Rosetta Energy Unit (REU)，不是 kcal/mol；cross-interface 分数不是结合自由能[5, 6]。

2.8 统计与缺失值规则

比例同时给出计数与分母；关键联合 RMSD 比例给出 Wilson 95% 置信区间。偏态指标优先报告中位数与四分位距。所有阈值采用严格不等号。数学上不可定义、未计算或源字段缺失的指标标记为“不可报告/未估计”，绝不以 0 代替。没有原始成对单体结构结果，因此单体 RMSD、pLDDT、能量和通透性均不作数值报告。

3 结果：单体序列恢复与甲基化分类

3.1 Ser 来源修正改变评价真值，但不改变模型输出

单体留出集包含 151 条肽、1505 个真实残基位点。来源复核后，旧标签中 62 个被写为 N-甲基 Ser 的位点改回天然 Ser；因此，论文主评价集由 261 个甲基化阳性和 1244 个阴性组成，阳性率为 $261/1505 = 17.34\%$ 。这一修正没有改变原始 frankenstein_v28.pt 的权重、基础氨基酸预测、甲基化概率或样本划分，改变的只有用于计算二分类指标的真值标签。

为避免把旧 323 阳性标签与修正真值混用，data/Monomer_Corrected_1505.csv 已将严格天然化输入的冻结概率逐位连接到修正 JSONL，并显式保留旧标签、修正标签、62 个修正标志和阈值 > 0.6 的判定列；三种输入模式的原始 4515 行推理表另存为 data/Monomer_RawPredictions_4515.csv，只作来源追溯。

所有正文结果均排除 padding，并使用严格判定 $p > 0.6$ 。旧标签及把 padding 计入分母的终端截图不参与正文估计；其来源和批大小依赖性仅在附录历史审计中说明（见附录 B）。

3.2 两个 Rosetta 来源面板的描述性分层

测试集的 83 条 Me_ 记录来自 Rosetta-2023 面板，68 条 pdb_ 记录来自 Rosetta-2025 面板；两者都不是 Baker 实验结构。分层结果见表 2。Rosetta-2025 面板的 RAA 和 F1 较高，但两个面板在构建版本、序列组成、长度和甲基阳性率上均可能不同，故这些差异只作异质性描述，不能解释为 Rosetta 版本升级或模型在某来源上的因果增益。

表 2 Ser 来源修正后，单体测试集按 Rosetta 理论结构面板分层的结果。F1 均使用严格 $p > 0.6$ 。

来源面板	单体/位点/阳性	RAA	已知序列 AUC/F1	端到端 AUC/F1
Rosetta-2023 (Me_)	83/763/114	12.19%	0.920/45.83%	0.931/51.90%
Rosetta-2025 (pdb_)	68/742/147	20.08%	0.886/59.69%	0.890/61.40%

3.3 RAA 与联合扩展 token 恢复率

天然化后，基础氨基酸预测正确 242 个位点，故单体 RAA 为

$$\text{RAA} = \frac{242}{1505} = 16.08\%. \quad (5)$$

RAA 只检验天然氨基酸类别，不评价甲基化状态。进一步要求“天然氨基酸类别正确，且在严格 $p > 0.6$ 下甲基化状态也正确”时，224 个位点满足条件，联合扩展 token 恢复率为

$$\text{Joint token recovery} = \frac{224}{1505} = 14.88\%. \quad (6)$$

端到端甲基二分类共有 111 个 TP，但其中只有 20 个位点的天然氨基酸类别也预测正确，另外 91 个位点虽然被判为甲基化，却甲基化了错误的氨基酸。因此，真实甲基残基的身份完全恢复率只有

$$\text{Exact methylated-residue recovery} = \frac{20}{261} = 7.66\%. \quad (7)$$

非甲基位点中另有204个位点同时预测对天然氨基酸和非甲基状态，故联合扩展 token 恢复为 $(20 + 204)/1505 = 224/1505$ 。天然化 RAA 的242个正确位点还包括17个“氨基酸正确但甲基漏检”和1个“氨基酸正确但误报甲基”的位置，所以 RAA 与联合 token 恢复相差18个位点。

表 3 原始 V28 在 Ser 来源修正单体留出集上的序列级结果。

指标	计数	比例	含义
天然化氨基酸恢复率 (RAA)	242/1505	16.08%	只要求天然氨基酸类别正确
联合扩展 token 恢复率	224/1505	14.88%	同时要求天然氨基酸类别和甲基化状态正确
端到端真实甲基残基身份完全恢复	20/261	7.66%	只在真实甲基位点中，同时要求氨基酸身份与甲基状态正确
RAA 正确但甲基状态错误	18/1505	1.20%	不能计作完整扩展 token 恢复

注：甲基化状态采用严格 $p > 0.6$ ；分母仅含1505个真实残基，不含 padding。

3.4 已知天然序列与端到端甲基化分类

在已知天然序列条件下，模型直接按真实天然残基类别选择甲基化专家头；在端到端条件下，则先预测天然残基，再按预测类别选择专家头。因此，前者衡量甲基化头本身，后者还包含基础序列错误的级联影响。

已知天然序列任务的 ROC-AUC 为0.9003。在严格 $p > 0.6$ 时，混淆矩阵为 $TP = 121$ 、 $TN = 1176$ 、 $FP = 68$ 、 $FN = 140$ ；Accuracy、Precision、Recall、F1 和假阳性率分别为86.18%、64.02%、46.36%、53.78% 和5.47%。模型在该口径下预测189个阳性位点，预测阳性率为12.56%，低于修正真值的17.34%。

端到端任务的 ROC-AUC 为0.9082。在同一严格阈值下， $TP = 111$ 、 $TN = 1230$ 、 $FP = 14$ 、 $FN = 150$ 。对应 Accuracy 与 Precision 为89.10%和88.80%，Recall 与 F1 为42.53%和57.51%，假阳性率为1.13%。端到端路径只预测125个阳性位点，预测阳性率为8.31%。相较已知天然序列任务，它减少了54个假阳性，但同时少识别10个真阳性；因此，较高的 Accuracy、Precision 或 AUC 不能解释为所有方面均优于已知序列任务。

表 4 Ser 来源修正标签下的单体甲基化分类结果（严格 $p > 0.6$ ）。

任务	AUC	TP	TN	FP	FN	Accuracy	Precision	Recall	F1	FPR	预测阳性率
已知天然序列	0.9003	121	1176	68	140	86.18%	64.02%	46.36%	53.78%	5.47%	12.56%
端到端	0.9082	111	1230	14	150	89.10%	88.80%	42.53%	57.51%	1.13%	8.31%

注：两项任务共享261个阳性和1244个阴性真值。AUC 为阈值无关的排序指标；其余指标均在预设严格阈值 $p > 0.6$ 下计算。




图 1 原始检查点在 Ser 来源修正单体留出集上的甲基化预测表现。A, ROC 曲线; B, 精确率-召回率曲线; C, 不同置信度阈值下的 F1; D, 严格 $p > 0.6$ 时的 Accuracy、Precision、Recall 与 F1。蓝色表示已知天然序列任务, 橙色表示端到端任务。所有曲线和计数均来自 1505 个真实残基位点, 不含 padding。

3.5 阈值结果的解释边界

修正标签后, 已知天然序列任务在阈值 0.3 处的 F1 高于阈值 0.6, 但 0.3 并非本文预设的部署阈值, 而且该最大值是在同一留出集上观察得到。为避免用测试集反向挑选阈值, 正文只报告预先冻结的严格 $p > 0.6$ 结果, 完整阈值敏感性由图 1 展示。若 RMC 表示端到端甲基阳性的二分类恢复, 它等于 Recall, 即 $111/261 = 42.53\%$; 若要求真实甲基残基的天然氨基酸身份也正确, 则为 $20/261 = 7.66\%$; 若以全部位点为分母计算完整扩展 token 恢复, 则为 $224/1505 = 14.88\%$ 。三者回答不同问题, 本文不把它们混称为一个 RMC。

甲基二分类 Accuracy 较高也不等于完整序列设计准确。修正集阴性位点占 82.66%, 而端到端 RAA 仅为 16.08%; 只有联合 token 恢复率同时反映基础类别和甲基状态。正文因此并列报告 RAA、甲基分类指标和联合 token 恢复率, 而不使用旧终端输出中的“Total End-to-End Acc”替代其中任何一项。

3.6 原始 V28 没有可报告的单体结构结果

单体 JSONL 中的坐标是 Rosetta 理论输入骨架, 不是端到端设计序列的预测结构。现有 runbook 曾规划 explicit-methyl 与 naturalized 的 HighFold 结构任务, 另有使用旧阈值 0.30 的参考/设计清单; 但与本文阈值 0.60 相符的预测结构、成对结果表、PyRosetta 能量和通透性原始文件均不在可

核验资产中。因此，原始 V28 的单体 CA/backbone/all-atom RMSD、甲基化位点 RMSD、pLDDT/pTM/PAE、能量、结构多样性和通透性均没有论文级数值。ipTM、界面 pLDDT、BSR 与受体框架姿态 RMSD 对单链单体本身也不适用。上述项目明确记为“未计算/不适用”，而不是 0；best85 或历史 V12 结果不得移植到 V28 单体队列。

4 六个非3AV复合物：温度0.5的预设主分析

本节只报告原始 frankenstein_v28.pt 在六个非3AV复合物（1SFI、3P8F、3WNE、3ZGC、4K1E和4KEL）上的结果。分析温度固定为 $T = 0.5$ ；甲基化判定沿用生成文件中保存的严格规则 $p > 0.6$ ，而不是 $p \geq 0.6$ 。所有比例均保留分子与分母，以区分两个回答不同问题的估计量：保留后条件成功率以476条含至少一个甲基化标记的设计为分母，端到端产率则以 544条原始生成成为分母。

4.1 从原始生成到可评价队列

在排除缓存目录中的重复文件后，六个靶点共得到544条原始序列；其中476条至少含一个由严格阈值产生并保存为小写字母的甲基化标记，总体保留率为 $476/544 = 87.50\%$ 。保留率存在明显的靶点差异：1SFI、3P8F、4K1E和4KEL 均为100/100，3WNE仅为27/84，3ZGC为49/60（表 5）。因此，单看保留后RMSD成功率会掩盖不同靶点生成有效甲基化序列的概率差异。

RMSD文件与生成记录采用“靶点名+区分大小写的设计序列”进行精确连接，476条保留记录全部一一匹配（476/476），没有因模糊匹配、序列自然化或缺失RMSD 而删除样本。图 2汇总了上述队列漏斗以及两种分母下的通过情况。

表 5 六个非3AV复合物的序列漏斗与端到端联合RMSD产率

靶点	原始生成	保留	保留率	联合 < 3 Å (分子/原始生成)	联合 < 5 Å (分子/原始生成)
1SFI	100	100	100.00%	1/100 (1.00%)	19/100 (19.00%)
3P8F	100	100	100.00%	2/100 (2.00%)	20/100 (20.00%)
3WNE	84	27	32.14%	3/84 (3.57%)	5/84 (5.95%)
3ZGC	60	49	81.67%	2/60 (3.33%)	23/60 (38.33%)
4K1E	100	100	100.00%	6/100 (6.00%)	24/100 (24.00%)
4KEL	100	100	100.00%	2/100 (2.00%)	10/100 (10.00%)
总体	544	476	87.50%	16/544 (2.94%)	101/544 (18.57%)

注：端到端产率将未通过甲基化保留门槛的原始生成也计入分母；因而它同时反映“生成有效甲基化序列”和“结构通过联合阈值”两个步骤。

4.2 RMSD分布与联合结构成功率

按照预设口径，每个样本只进行一次全复合物CA叠合；随后在该坐标系内，对末链环肽采用完整CA配对和最佳正向循环移位，不允许反向遍历，也不进行第二次肽链单独拟合。联合通过要求同一条设计的全复合物CA RMSD与最佳正向循环肽CA RMSD 同时严格小于相应阈值。

在476条保留设计中，全复合物CA RMSD的总体中位数为 1.022 [0.692, 1.534] Å，最佳正向循环肽CA RMSD的总体中位数为 6.738 [5.261, 8.129] Å（中括号内为四分位距，表 6）。全复合物部分有469/476 = 98.53%低于3 Å，且476/476 = 100% 低于5 Å；因此总体失败主要由环肽在已经对齐的复合物坐标系中的位置或构象偏差驱动，而不是受体整体叠合失败。

联合 < 3 Å 共有16条，保留后条件成功率为 $16/476 = 3.36\%$ ，95% Wilson置信区间为2.08%–5.39%；联合 < 5 Å 共有101条，条件成功率为 $101/476 = 21.22\%$ ，95% Wilson 置信区间为17.78%–25.11%。换用544条原始生成作分母时，对应端到端产率分别为2.94%（95% Wilson置信区




图2 六个非3AV复合物的队列漏斗与RMSD通过率 (Fig. 1)。(A) 各靶点原始生成及严格 $p > 0.6$ 后保留数量；(B) 各靶点联合RMSD类别；(C) 总体全复合物、环肽以及二者联合的通过率。图中的结构通过率以476条 保留设计为分母；从544条原始生成开始的端到端产率另见 表5。

间1.82%–4.72%) 和 18.57% (15.52%–22.05%)。这两组数字不可互换：前者评价已生成 有效 甲基化标记后的结构质量，后者回答一次原始生成最终得到合格设计的概率。

表 6 保留设计的RMSD分布与联合通过率

靶点	保留数	全复合物CA RMSD 中位数 [IQR] (Å)	循环肽CA RMSD 中位数 [IQR] (Å)	联合 < 3 Å 分子/保留数 (%)	联合 < 5 Å 分子/保留数 (%)
1SFI	100	0.884 [0.581, 1.457]	6.289 [5.239, 7.814]	1/100 (1.00)	19/100 (19.00)
3P8F	100	0.981 [0.445, 1.364]	6.375 [5.301, 7.282]	2/100 (2.00)	20/100 (20.00)
3WNE	27	0.904 [0.893, 0.927]	29.002 [22.337, 39.916]	3/27 (11.11)	5/27 (18.52)
3ZGC	49	2.337 [1.662, 2.742]	5.219 [4.367, 6.377]	2/49 (4.08)	23/49 (46.94)
4K1E	100	1.041 [0.691, 1.517]	6.803 [5.071, 7.809]	6/100 (6.00)	24/100 (24.00)
4KEL	100	1.133 [0.701, 1.491]	7.791 [6.361, 10.364]	2/100 (2.00)	10/100 (10.00)
总体	476	1.022 [0.692, 1.534]	6.738 [5.261, 8.129]	16/476 (3.36)	101/476 (21.22)

注：IQR为第25至第75百分位。表内百分比均以本靶点“保留数”为分母；总体 < 3 Å 与 < 5 Å 比例的95% Wilson置信区间 分别为2.08%–5.39%和17.78%–25.11%。

靶点层面的结果进一步说明为什么必须同时报告分子与分母。3WNE的环肽RMSD 中位数最高 (29.002 Å)，但仍有3/27条低于3 Å；由于其 仅保留27条，换成原始生成分母后为3/84 = 3.57%。3ZGC的条件联合 < 5 Å比例最高 (23/49 = 46.94%)，其端到端产率则为 23/60 = 38.33%。这些描述性差异不应被解释为经多重比较校正后的靶点排名。完整分布及两个RMSD之间的关系见图 3。

作为表示方式敏感性分析，如果不允许循环移位而强制使用固定残基顺序，联合 < 3 Å 和 < 5 Å 分别仅为2/476 = 0.42%和 33/476 = 6.93%；采用最佳正向循环移位后分别为16/476 = 3.36%和 101/476 = 21.22%。这一变化反映环状序列起点的表示等价性，并非重新生成或 重新拟合后的模型性能提升；主结果始终使用预先规定的最佳正向循环移位口径。

4.3 甲基化输出的组成

图 4给出476条保留设计中甲基化位点和每条序列甲基化 数量的分布。这里的小写字母只是原始生成器在严格 $p > 0.6$ 规则下保存的预测 甲基化标记；它们不是实验测得的修饰状态，也不能据此推断真实酶学位点偏好。该图的作用是描述进入RMSD分析的设计队列，而不是重新评价甲基化分类器的独立准确率。

4.4 每靶点oracle代表与选择条件化的下游读数

为便于逐个靶点查看具体序列，从每个靶点的保留设计中选取最佳正向循环肽CA RMSD最小的一条，得到六条oracle代表 (表 7)。六条代表的 循环肽RMSD均低于3 Å，但这一事实是选择规则的直接结果，不能代替 随机或预先固定候选上的成功率估计。图 5汇总这些代表的 RMSD、预测通透性、固定构象PyRosetta界面能以及结构文件CA B-factor均值代理量。

表 7 六个靶点按最小循环肽RMSD选择的oracle代表

靶点	设计序列	甲基化位点	全复合物 RMSD (Å)	循环肽 RMSD (Å)	预测通透性 (模型单位)	固定构象 界面能 (REU)	CA B-factor 均值代理量
1SFI	RCCrGNCGQCQFGG	4	0.536	2.818	0.454	31.77	93.49
3P8F	CrrrGrQGKGrRGC	2,3,4,6,11	0.300	2.075	7.57×10^{-35}	−25.73	91.57
3WNE	GrKWNC	2	0.933	1.459	0.0864	0.73	90.03
3ZGC	rEGGQNR	1	0.973	2.076	1.04×10^{-7}	15.95	89.91
4K1E	rcrrrQCrQGNCrDR	1,2,3,4,5,8	0.900	1.916	6.14×10^{-32}	434.24	89.04
4KEL	RcrrGNCrQGFCrDR	2,3,4,8	0.655	2.379	0.00214	416.77	91.49

注：每行均在观察该靶点全部候选的循环肽RMSD后再选择，故所有 后续读数均为选择条件化描述。CA B-factor均值只是相应结构文件字段的代理量，不应与来自另一流程、另一标定方式的pLDDT直接等同。通透性列没有实验标签，也没有校准到物理单位。




图3 六个非3AV复合物的RMSD分布与关系 (Fig. 2)。全复合物CA RMSD 来自唯一一次全复合物叠合；循环肽CA RMSD在同一坐标系内采用最佳正向循环 移位计算。虚线标示3 Å与5 Å阈值。




图4 保留设计的预测甲基化位置与数量 (Fig. 3)。序列中的小写残基表示 原始生成文件按严格 $p > 0.6$ 保存的甲基化预测；位点编号为设计肽链的1基坐标。

oracle选择警告

表 7 中的序列并非预先指定，也不是从 476 条设计中随机抽取；它们是在观察目标结局——循环肽 RMSD——之后逐靶点取最小值。因此，代表序列及图 5 中的下游指标只能用于候选展示和后续验证优先级，不能用于估计模型的总体成功概率，也不能把六条代表的均值当作未选择队列的无偏性能。通透性预测同样是在该选择之后报告，应视为探索性结果。固定构象 PyRosetta 界面能未经过统一松弛或重打包，而结构文件中的 highfold_ca_bfactor_mean 仅作置信度代理；二者均不构成实验结合或稳定性证据。无选择偏倚的成功率应以表 5 和表 6 中的全部 544 条或 476 条记录为准。

5 17 靶点的探索性支持结果

5.1 天然复合物集合不能评价甲基阳性召回

17 个天然复合物共包含 251 个选中短肽位点；天然结构的序列评价保留预先选定的全部短肽链，部分靶点因此贡献多条等价肽链，而生成结构评价只使用单条预测末链。天然化基础序列恢复为 53/251 (21.12%)。这 251 个真值位点全部是未甲基化阴性，因此 ROC-AUC、Precision、Recall 和 F1 都没有阳性类别可供计算；若给出这些数字，数学上没有意义。阈值严格 $p > 0.6$ 时，已知天然序列条件产生 19 个假阳性 (19/251, 7.57%)，端到端条件产生 9 个预测甲基位点 (9/251, 3.59%)。后一个比例同时受基础氨基酸预测错误影响，不能解释为甲基化头单独的假阳性率。

表 8 17 个天然复合物上的可报告序列指标。所有甲基化真值均为阴性。

指标	计数	比例	解释
天然化 RAA	53/251	21.12%	基础氨基酸恢复
已知序列甲基假阳性	19/251	7.57%	真阴性集合上的 FPR
端到端预测甲基位点	9/251	3.59%	含基础类别级联误差
AUC/Precision/Recall/F1	—	不可定义	没有甲基阳性真值

5.2 五个温度的生成覆盖与重复率

原始全温度文件共有 4015 条记录；分别在每个温度内去重后合计 3443 条。比较两个端点，温度内唯一率在 $T = 0.01$ 与 0.5 时分别为 78.05% 和 94.88%，平均天然序列恢复分别为 1.49% 和 4.42%，平均甲基标记率分别为 27.69% 和 9.67% (表 9)。其中唯一率在 $T = 0.1$ 降至 74.37%，所以这些变化并非全程单调。它们是生成池的描述统计，不是独立同分布实验重复，也不能把不同温度的样本量差异解释为温度效应的因果证据。

表 9 17 靶点原始生成池的温度分层统计。唯一数是在各温度内去重；甲基标记率为序列内小写甲基 token 比例的均值。

T	原始数	唯一数	重复数	唯一率	平均 RAA	平均甲基率
0.01	82	64	18	78.05%	1.49%	27.69%
0.10	394	293	101	74.37%	2.46%	23.24%
0.20	776	597	179	76.93%	3.52%	19.87%
0.30	1181	988	193	83.66%	3.90%	15.54%
0.50	1582	1501	81	94.88%	4.42%	9.67%
合计	4015	3443	572	85.75%	—	—




图 5 六条oracle代表的选择条件化下游指标 (Fig. 5)。 (A) 全复合物与循环肽RMSD； (B) 预测通透性 (log10尺度)； (C) 固定构象PyRosetta界面能； (D) 结构文件CA B-factor均值代理量。所有面板均须结合正文的oracle选择警告解释。

5.3 best85: 肽内部形状尚可，但结合姿态普遍偏离

旧 best85 队列覆盖 $17 \times 5 = 85$ 个靶点-温度组合，结构文件和链映射均为 85/85。由于每个组合的代表是按真实天然序列恢复率从多个候选中选出，这一队列是选择条件化的 oracle 集合；它回答“知道天然答案后所挑代表的表现”，不回答一次盲生成的期望表现。

在受体框架对齐后，肽 CA RMSD 的均值/中位数为 29.93/40.06 Å，肽 backbone RMSD 为 29.83/39.96 Å；CA RMSD < 2 Å 为 0/85， < 5 Å 为 3/85 (3.53%)。相反，单独对肽自身拟合后，CA 与 backbone RMSD 的均值/中位数分别为 2.65/2.53 Å 和 2.34/2.11 Å (表 10)。这组巨大差异说明，部分序列可形成与天然肽相似的内部形状，但没有位于正确的受体结合位置；因此不能用肽自对齐 RMSD 宣称设计成功。

表 10 best85 的旧结构评价。受体框架对齐反映结合姿态；肽自对齐仅反映内部形状。

指标	n	均值 (Å)	中位数 (Å)
受体拟合后肽 CA RMSD	85	29.930	40.064
受体拟合后肽 backbone RMSD	85	29.835	39.960
肽自拟合 CA RMSD	85	2.647	2.530
肽自拟合 backbone RMSD	85	2.342	2.105

best85 共含 159 个模型标记的甲基位点和 626 个非甲基位点。按两组坐标平方和合并后开方得到的 pooled CA RMSD，在受体拟合后分别为 20.43 与 34.18 Å，在肽自拟合后分别为 3.28 与 2.93 Å；这些数值不是逐设计或逐位点 RMSD 的算术均值。由于位点是否甲基化本身由模型选择，并同时关联残基类别、靶点、温度和结构可解析性，这只是选择后的描述，不能推出“甲基化导致更好结合姿态”或其他因果关系。

5.4 多样性、置信度、通透性和 fixed-pose 分数

同一靶点的五个温度代表进行两两比较，共得到 170 对。对称 TM-score 的均值与中位数分别为 0.340 和 0.309；对应多样性 $1 - TM$ 分别为 0.660 和 0.691，提示代表结构之间存在较大内部形状差异。但它既受温度影响，也受 oracle 挑选影响，不等价于完整生成分布的多样性。

结构 PDB 的 CA B-factor 代理在 85/85 条中可用，均值为 87.55。HighFold COMMENT 的 global pLDDT、肽链 pLDDT、pTM 和受体-肽 ipTM/PAE 字段仅在 37/85 条中存在；在这些可用条目中，global pLDDT、肽链 pLDDT、pTM 与受体-肽 ipTM 的均值分别为 71.07、46.53、0.146 和 0.461，肽链内 PAE、链间 PAE 与界面 PAE 的均值分别为 3.64、18.05 和 12.14。缺失的 48 条不能填零，PDB B-factor 代理也不能替代 COMMENT 字段。

预测通透性在 85/85 条中有数值：82 条由靶点、序列和温度严格匹配，3 条（3WNE 的 $T = 0.01/0.1$ 与 3ZGC 的 $T = 0.1$ ）因同一序列跨温度重复而回填，故温度分层图包含这项来源限制。总体中位数为 1.84×10^{-8} （模型单位）；两个端点 $T = 0.01$ 与 0.5 的中位数分别为 3.17×10^{-9} 与 5.16×10^{-6} ，但 $T = 0.1$ 为 2.43×10^{-9} ，并非全程单调。由于没有实验通透性标签，这只能视为模型预测分布，不能报告准确率或外部验证结论。

自然化 fixed-pose PyRosetta 评分覆盖 85/85 条。复合物每残基分数的中位数为 1.799 REU，cross-interface 分数的均值/中位数为 259.97/110.07 REU，只有 6/85 为负。该流程没有在同一参数化、同一优化协议下计算天然参考，也没有显式 N-甲基残基参数；因此无法计算“低于天然能量”的 success 或 stability，更不能把这些数值称为结合自由能。




图 6 17 靶点 best85 的探索性支持结果。A，靶点内五温度代表的 1 - TM 分布；B，按温度分层的通透性预测，其中3条为相同序列的跨温度回填；C，自然化 fixed-pose cross-interface Rosetta 分数；D，各指标的文件可用数。所有面板均受 oracle 选择影响，不能替代六复合物的预设主分析。

6 讨论

6.1 原始模型的能力边界

本次统一审计显示，原始 Frankenstein-v28 的甲基化头并非完全失效：修正真值后，已知序列与端到端 AUC 仍分别达到 0.900 和 0.908，说明预测分数对阳性、阴性位点具有排序信息。然而，固定在项目预设阈值 > 0.6 时，Recall 只有 46.36% 和 42.53%，意味着超过一半真实甲基位点没有被保留。与此同时，天然化 RAA 只有 16.08%，所以“甲基分类不错”和“完整扩展氨基酸序列恢复好”不能互相替代。

六个非 3AV 复合物给出了更接近实际筛选流程的答案。544 条温度 0.5 原始序列中，476 条通过甲基保留门；联合 $\text{RMSD} < 5 \text{ \AA}$ 的最终端到端产率为 18.57%， $< 3 \text{ \AA}$ 为 2.94%。如果只对 476 条保留样本报告 21.22% 和 3.36%，会忽略甲基门带来的损失，因此本文同时固定两个分母。

结构误差的主要来源也很清楚：476 条中 469 条全局复合物 CA $\text{RMSD} < 3 \text{ \AA}$ 、全部 476 条 $< 5 \text{ \AA}$ ，但联合通过数只有 16 和 101。换言之，瓶颈不是整体受体框架，而是同一全局坐标系内的环肽结合姿态。best85 中“肽自拟合约 $2.65 \text{ \AA}$ 、受体框架拟合后约 $29.93 \text{ \AA}$ ”的差距从另一队列支持了同一解释，但因选择方式和 RMSD 定义不同，不能把两个队列合并计算。

6.2 不同靶点需要不同诊断

六个靶点没有表现出统一失败模式。3WNE 的甲基保留率只有 27/84 (32.14%)，且保留后环肽 RMSD 中位数达到 $29.00 \text{ \AA}$ ，甲基门和结合姿态都是瓶颈。3ZGC 的保留率为 49/60 (81.67%)，联合 $< 5 \text{ \AA}$ 的原始产率达到 38.33%，但其全局 RMSD 中位数 $2.34 \text{ \AA}$ 高于其他靶点，提示整体结构拟

合仍需关注。1SFI、3P8F、4K1E 和 4KEL 全部通过甲基保留门，但联合 $< 5 \text{ \AA}$ 的原始产率仍只有 10–24%，说明仅提高甲基标记概率并不能解决姿态问题。

因此，后续模型改进不宜只优化一个总体 Accuracy。更合理的错误分解是：基础残基类别、甲基化判断、完整序列有效率、受体框架质量、环肽内部形状和环肽结合姿态分别追踪，并按靶点报告。只有这样才能判断修改真正修复了哪一步。

6.3 数据审计为何改变结论

旧单体标签把 62 个 Ser 错列为甲基阳性，旧评价脚本又把批次 padding 的零初始化位置当作真实阴性。前一个问题改变真值，后一个问题使结果依赖 batch size。两者都会产生表面上更好、却不可复现的 Accuracy 或 F1。本文没有改变检查点和位点预测概率，只修正评价标签并限制到 1505 个真实位点，因此主结果应视为对同一模型的更干净估计，而不是一次新的训练结果。

数据来源审计还改变了单体集合的性质判断。规划截图提出了“Baker 33”和“Rosetta 400+300”，但逐文件复核显示 751/751 个原始 PDB 均声明为 Rosetta 理论模型，其中 406 个来自 Rosetta-2023、345 个来自 Rosetta-2025；没有找到可核验的 Baker 33 实验结构子集。因此，截图应被视为早期规划，而不能覆盖冻结数据本身。当前仍缺少的是 checkpoint 的完整训练 manifest 与同源聚类级泄漏审计，而不是这些 PDB 的 Rosetta 理论来源。

6.4 限制与尚未完成的论文指标

本稿的主要限制如下：

- 151 个单体没有与原始 V28 一一对应的预测结构结果，因此不能报告单体 CA/backbone/all-atom RMSD、pLDDT、能量或通透性。历史 164 条结构表属于 V12 工作流，不能移植到 V28。
- 六复合物主分析有 CA 层面的全局与环肽 RMSD，但没有统一可用的 backbone/all-atom 甲基化 RMSD、结合位点恢复、同靶点完整多样性或原生对照能量。
- best85 使用真实天然序列恢复率挑选，存在 oracle 选择偏倚；其结果不能代表盲生成或 100 条/靶点的未来批次。
- 置信度、通透性与 Rosetta 分数均为计算量，尚无实验结构、实验通透性、亲和力或稳定性验证。
- 主要比例来自 6 个靶点，靶点间异质性明显；逐序列 Wilson 区间不包含靶点抽样不确定性。
- 本稿为既有文件的回顾性整合，没有重新运行上游模型；这保证了口径唯一，但无法补回从未生成的指标。

6.5 下一步最小充分验证

对后续修复模型，建议保持本稿所有阈值和分母不变，先在 17 个复合物每靶点 100 条的盲生成集上冻结序列，再统一生成结构。预先登记的主要终点应是：原始生成分母上的含甲基有效率、全局对齐后环肽姿态 RMSD < 3 和 $< 5 \text{ \AA}$ 比例；次要终点才是肽自拟合 RMSD、置信度、多样性、通透性预测和同协议天然对照能量。模型修复前后必须使用相同靶点、随机种子规划、结构生成器版本和 RMSD 脚本，且禁止用天然序列恢复率挑选代表。只有这一步通过，才适合扩大到每靶点 1000 条。

7 结论

本研究把原始 frankenstein_v28.pt 的单体和复合物证据首次统一到一个可追溯口径。Ser 来源修正后，模型的甲基化排序能力仍然存在，但固定阈值下召回有限，且基础序列恢复率较低。六个非 3AV 复合物在温度 0.5、严格甲基置信度 > 0.6 下，从 544 条原始生成出发，联合 RMSD < 3 和 $< 5 \text{ \AA}$ 的端到端产率分别为 2.94% 与 18.57%；环肽结合姿态是主要结构瓶颈。

17 靶点 best85 的多样性、置信度、通透性和 fixed-pose 能量提供了探索性背景，但其 oracle 选择和指标缺失不允许把它解释为部署成功率。尚无原始 V28 单体结构结果，也尚无统一的全原子

甲基 RMSD、BSR、相对天然能量 success/stability 或实验通透性。因而，本稿适合作为后续 V8 修复和 1700 条盲生成验证的冻结基线，而不是终点性能宣称。

A 尚哥指标清单的证据可用性矩阵

本附录逐项对应尚哥提供的模型、数据和指标提纲。全文涉及的五层分母严格分开：

1. **单体**：Ser 来源修正留出集，151条、1505个真实位点，正文阈值严格 $p > 0.6$ ；
2. **六复合物主分析**：六个非 3AV 靶点、 $T = 0.5$ 、544条原始序列和476条甲基化保留候选；
3. **天然17靶点**：预先选定的全部短肽链，共251个天然位点；
4. **17靶点全温度生成池**：五个温度共4015条原始记录、3443条温度内唯一序列；
5. **best85 探索集**：17个靶点、五个温度、按天然序列恢复率选择的85个 oracle 代表。

状态含义如下：**可报告**表示定义、分母和来源均已冻结；**探索性**表示数值存在，但受 oracle 选择、预测模型或非实验代理限制；**不可定义**表示真值类别缺失，数学上不能计算；**未计算**表示没有合格的成对数据或冻结定义。任何“不可定义/未计算”均不等于数值0。

A.1 模型、数据与序列指标

表 11 模型、数据与序列指标的队列级可用性。

清单项目	单体	六复合物主分析	17靶点探索 (天然/生成/best85)	状态与原因
基于甲基化单体的微调	冻结检查点可评价；历史审计记录 train/test 为600/151，但无原始训练全过程日志、随机种子曲线和相对于初始化模型的配对增益	使用同一冻结检查点生成/评分，不构成新的训练证据	天然集、全温度池和 best85 均使用同一冻结检查点；oracle 选择不能反推微调增益	部分可报告 ：可写模型和检查点，不可编造“微调提高了多少”
甲基化分类器	known-sequence 与 end-to-end 均有261阳性/1244阴性真值	75个天然位点全为阴性；476条生成序列无实验甲基真值	天然251位点全为阴性；全温度池和85条代表只有模型小写标记，无实验甲基真值	单体 可报告 ；复合物生成序列只能报告标记/保留率
Baker 33 个真结构单体	未找到；751/751 个原始 PDB 均标记为 Rosetta 理论模型，没有可核验的 Baker 实验结构子集	不适用	不适用	与冻结数据不符 ：不得把规划数字写成已完成数据
Rosetta 400+300 个单体	实际为406个 Rosetta-2023 与345个 Rosetta-2025 理论模型，合计751；训练/测试为600/151	不适用	不适用	可报告实际构成 ：规划的400+300数字不采用
17 个真结构复合物	不适用	从17个靶点中预设选取六个非3AV靶点	天然17靶点用于序列评价；best85为85/85结构匹配	可报告 ，但六靶点与 best85 的队列和 RMSD 定义不同
RAA（天然化氨基酸恢复）	242/1505 = 16.08%	天然六复合物七条选定肽链为 29/75 = 38.67%；不得与476条生成候选的回收字段混为同一测试	天然17靶点为53/251 = 21.12%；全温度池按温度的平均RAA为 1.49–4.42%；best85的 recovery 是 oracle 选择标准	单体、天然六复合物和天然17靶点 可报告 ；生成池为描述性，best85有 选择偏倚
AUC	known-sequence 0.9003；end-to-end 0.9082	天然75位点阳性数为0，AUC不可定义；生成476条无实验真值	天然251位点无阳性，AUC不可定义；生成池与best85无实验甲基真值	仅单体 可报告

接下页

表11 (续)

清单项目	单体	六复合物主分析	17靶点探索 (天然/生成/best85)	状态与原因
Accuracy (严格 $p > 0.6$)	known 1297/1505 = 86.18%; end-to-end 1341/1505 = 89.10%	天然阴性集 known 71/75 = 94.67%; end-to-end 73/75 = 97.33%, 实质为 1 – FPR; 生成476条不可计算	天然17靶点 known 232/251 = 92.43%、 end-to-end 242/251 = 96.41%, 实质 为1 – FPR; 生成池与best85不 能计算	单体 可报告 ; 两个天然复合 物阴性集仅作误报审计
Precision / Recall / F1	known 64.02%/46.36%/ 53.78%; end-to-end 88.80%/42.53%/57.51%	天然位点无阳性, 三项不可定 义; 生成候选无真值	天然251位点无阳性, 三项不 可定义; 生成池与best85无实 验真值	仅单体 可报告
RMC	二分类甲基召回 111/261 = 42.53%; 端到端真 实甲基残基身份完全恢复 20/261 = 7.66%; 全部位点联 合 token 恢复 224/1505 = 14.88%	同理; 因无阳性, 不能把RMC写 成0	天然251位点无阳性, 不能把 RMC写成0; 生成池与best85 无真值	术语歧义 : 必须同时写明身 份要求与分母
FPR / 预测阳性率	known FPR 5.47%、预测阳 性率12.56%; end-to-end 1.13%、8.31%	天然阴性集 known 4/75 = 5.33%; end-to-end 2/75 = 2.67%	天然17靶点 known FPR 19/251 = 7.57%; end-to-end 预测阳性率9/251 = 3.59%; 生 成池可统计小写率但不能称 FPR	单体及两个天然阴性集 可报 告
联合扩展 token 恢复	基础类别与甲基状态同时正 确: 224/1505 = 14.88%	未形成可复核的75位点联合交叉 表; 生成候选无扩展 token 真值	天然17靶点未形成联合交叉 表; 生成池与best85无扩展 token 真值	仅单体 可报告 ; 不能用 RAA 与 Accuracy 相乘替代
甲基化保留率/有 效生成概率	不适用; 这是生成队列指标	476/544 = 87.50% 含至少一个 严格 $p > 0.6$ 的已保存小写标 记; 联合 $< 3 / < 5$ 原始产率为 16/544 = 2.94%、101/544 = 18.57%	全温度池有4015条记录, 但未 定义与主队列相同的端到端结 构成功门; best85固定为85个 oracle代表	六复合物主 结果可报告
旧标签/旧 padding 阈值截 图	不进入正文; 旧标签含62个 Ser来源错误, 旧截图分母随 batch size 改变	不适用	不适用	仅 历史审计 : 不可与本表正 文指标并列

A.2 结构、能量、多样性与通透性指标

表 12 结构与下游指标的队列级可用性。

清单项目	单体	六复合物主分析	17靶点探索 (天然/生成/best85)	状态与原因
RMSD_CA	无端到端单体设计结构-参考结构配对	476/476有一次全复合物对齐后的全局 CA 与末链 best-forward 环肽 CA RMSD；总体中位数[IQR]分别为 1.022[0.692–1.534]和 6.738[5.261–8.129] Å	受体 CA 拟合后肽 CA mean/median=29.93/40.06 Å；肽自对齐 =2.65/2.53 Å	六复合物与 best85 均可报告，但定义不同，禁止合并
RMSD_Backbone	未计算	476条主队列未计算完整 backbone RMSD；只有选择后的旧代表字段，不能替代全队列	N/CA/C：受体拟合后 mean/median=29.83/39.96 Å；肽自对齐 =2.34/2.11 Å，85/85	best85可报告；六主队列未计算
RMSD_All	未计算	未计算	未计算	缺失：需要非标准/甲基残基的可靠全原子映射
RMSD_CA Methylation	未计算	六个按肽 RMSD 选择的代表有旧位点字段，但不是476条主队列的无偏汇总	159个甲基标记位点与626个非甲基位点：受体拟合 pooled CA=20.43/34.18 Å；肽自拟合 =3.28/2.93 Å	best85描述性；分组非随机，不能推断甲基化因果效应
RMSD_Backbone Methylation	未计算	仅选择后的旧代表字段；主队列未汇总	N/CA/C 位点结果按温度可用，85/85；无显式甲基原子	best85描述性
RMSD_All Methylation	未计算	未计算	未计算	缺失：没有显式 N-甲基全原子对应关系
pLDDT	无单体设计结构结果	六个选择后代表仅有 highfold_ca_bfactor_mean，不能改名为 COMMENT global pLDDT	COMMENT global pLDDT 37/85 (mean 71.07)；CA B-factor代理 85/85 (mean87.55)，二者分开报告	best85部分可用；缺失不得填0
ipLDDT	未定义/未计算	未定义/未计算	没有名为 ipLDDT 的冻结字段；最近的字段是 peptide-chain pLDDT，37/85 (mean46.53)	术语未定义：若指界面/肽链 pLDDT，须按真实字段改名
pTM	未计算	六个选择后代表缺失	peptide-chain pTM 37/85 (mean0.146)	best85仅部分可用
ipTM	未计算	六个选择后代表缺失	peptide–receptor ipTM 37/85 (mean0.461)	best85仅部分可用
pAE / PAE	未计算	六个选择后代表缺失	peptide-chain PAE mean3.64、inter-PAE mean18.05、iPAE mean12.14，均37/85	best85仅部分可用；不能由 PDB坐标补造

接下页

表12 (续)

清单项目	单体	六复合物主分析	17靶点探索 (天然/生成/best85)	状态与原因
BSR (binding-site ratio)	未定义/未计算	未定义/未计算	未定义/未计算	缺失 : 须先冻结接触原子、距离阈值以及 precision/recall 方向
Success: 肽能量低于天然	无设计/天然同流程能量对于天然	六代表只有设计 fixed-pose 分数, 无同流程天然肽基线	只有设计 fixed-pose 分数, 无同流程天然肽基线	不可计算 ; 界面分数 < 0 不能替代 “低于天然”
Stability: 复合物能量低于天然	无设计/天然同流程能量对	无同流程天然复合物能量	无同流程天然复合物能量	不可计算
Designability: RMSD < 2 Å	无结构对	按 Task 1 联合定义为 2/476 = 0.42%; 以全部544条为分母为 2/544 = 0.37%	受体框架肽 CA RMSD < 2 为 0/85	可由现有RMSD计算 ; 须连同定义和分母报告
预设 RMSD < 3/< 5 Å	不适用	保留后联合通过 16/476 = 3.36%、101/476 = 21.22%; 原始产率2.94%、18.57%	旧受体框架肽 CA < 5 为 3/85 = 3.53%, < 3 为 0/85	可报告 , 但两队列定义不同
Diversity: 1 – TM	未计算	每靶点只取一个选择后代表, 靶内多样性不可估计	17靶点内170/170对; mean/median 1 – TM = 0.660/0.691	best85 探索性 : 肽自对齐内部形状且受oracle选择影响
膜通透性	无单体结果	六个按肽 RMSD 选择的代表6/6有预测值; 属于选择条件化展示, 不代表 476条总体	best85为85/85有预测值, 其中82条严格温度匹配、3条相同序列跨温度回填; 总体 median 1.84×10^{-8} , 无实验标签	探索性预测 : 不能声称实验透膜性提高
Rosetta 能量/分数	无单体结果	六个选择后代表有自然化 fixed-pose 界面分数; 仅作条件化示例	85/85; complex score/residue median1.7995 REU, cross-interface median110.07 REU, < 0 为6/85	探索性 : 非自由能、非亲和力、非相对天然稳定性
单体结构结果总体状态	与本文阈值0.60一致的设计结构和成对结果表缺失; 旧阈值任务清单不能用于本文	不适用	复合物结果不得移植到单体	明确缺失 : 单体结构指标均不填数

A.3 矩阵所引用的冻结数据资产

上述数值来自随稿提供的单体逐位主表与标准化阈值曲线、476条候选总表、六复合物主表以及 best85 的结构、甲基位点、多样性、通透性和 fixed-pose 能量 CSV。机器可读文件统一位于 data/，文件索引、关键哈希与上游逻辑来源见 SOURCE_MANIFEST.json。旧终端截图仅保留在补充材料中，用于说明 padding 与历史标签错误；其数值不参与正文、摘要或本矩阵的主结果。

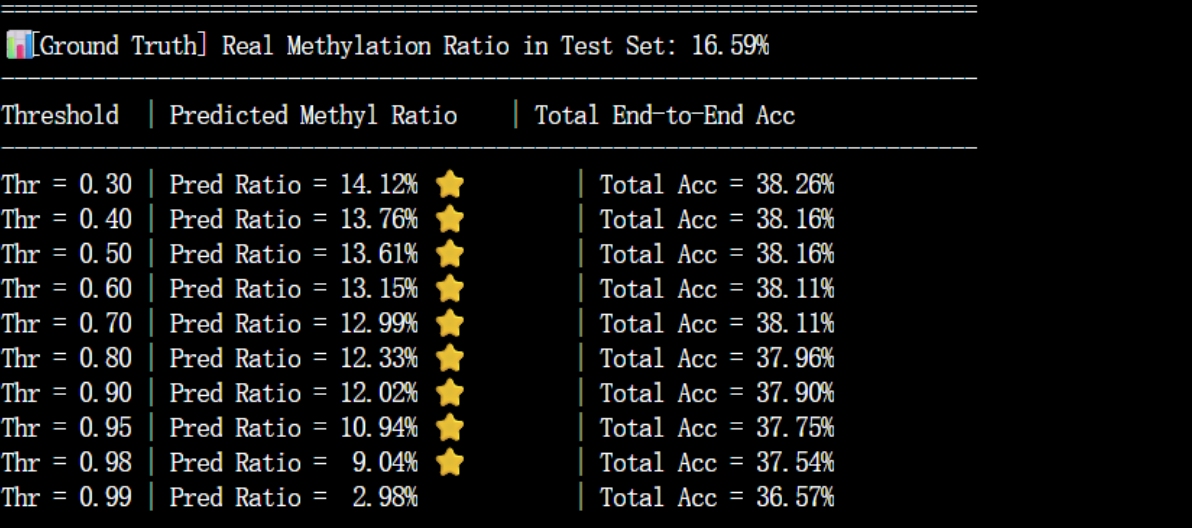
B 历史截图、旧标签与 padding 错误复盘

B.1 两张终端截图为什么不能作为论文主表

用户提供的第一张历史截图把 “Ground Truth Real Methylation Ratio” 显示为 16.59%。这一数值可以被精确重构为

$$\frac{323}{1505 + 442} = 16.5896\%, \quad (8)$$

即 1505 个真实位点之外又计入 442 个 batch padding 位置。在阈值 0.6 时，截图的预测甲基率 13.15% 对应 256/1947，所谓 total end-to-end accuracy 38.11% 对应 742/1947。它们的分母都不是实际测试位点数。



[Ground Truth] Real Methylation Ratio in Test Set: 16.59%		
Threshold	Predicted Methyl Ratio	Total End-to-End Acc
Thr = 0.30	Pred Ratio = 14.12% ★	Total Acc = 38.26%
Thr = 0.40	Pred Ratio = 13.76% ★	Total Acc = 38.16%
Thr = 0.50	Pred Ratio = 13.61% ★	Total Acc = 38.16%
Thr = 0.60	Pred Ratio = 13.15% ★	Total Acc = 38.11%
Thr = 0.70	Pred Ratio = 12.99% ★	Total Acc = 38.11%
Thr = 0.80	Pred Ratio = 12.33% ★	Total Acc = 37.96%
Thr = 0.90	Pred Ratio = 12.02% ★	Total Acc = 37.90%
Thr = 0.95	Pred Ratio = 10.94% ★	Total Acc = 37.75%
Thr = 0.98	Pred Ratio = 9.04% ★	Total Acc = 37.54%
Thr = 0.99	Pred Ratio = 2.98%	Total Acc = 36.57%

图7 历史端到端阈值截图。该次运行的有效数组长度为 1947，其中 442 个为 padding，故比例不能用于论文。原始图片仅用于审计留档。

第二张截图可被另一种 batch 切分精确重构：有效数组长度为 $1505 + 386 = 1891$ ，正类仍是 323，padding 被当作阴性后阴性总数变成 1568。阈值 0.6 时混淆矩阵为 $TP = 90$ 、 $FP = 38$ 、 $TN = 1530$ 、 $FN = 233$ ，从而得到截图中的 Accuracy 85.67%、Precision 70.31%、Recall 27.86% 和 F1 39.91%。若模型全部预测阴性，Accuracy 仍为

$$\frac{1568}{1891} = 82.9191\%, \quad (9)$$

正好对应截图在阈值 0.95–0.99 的 82.92%。这说明结果会随 batch size 改变，而不是模型本身改变。

Threshold	Binary Accuracy	Precision (精准率)	Recall (召回率)	F1-Score
Thr = 0.30	51.35%	22.59%	76.16%	34.84
Thr = 0.40	68.75%	28.53%	55.11%	37.59
Thr = 0.50	80.43%	42.24%	39.63%	40.89
Thr = 0.60	85.67%	70.31%	27.86%	39.91
Thr = 0.70	86.67%	92.77%	23.84%	37.93
Thr = 0.80	85.99%	100.00%	17.96%	30.45
Thr = 0.90	83.13%	100.00%	1.24%	2.45
Thr = 0.95	82.92%	0.00%	0.00%	0.00
Thr = 0.98	82.92%	0.00%	0.00%	0.00
Thr = 0.99	82.92%	0.00%	0.00%	0.00

图 8 历史二分类阈值截图。该次运行多计入 386 个 padding 阴性；所有显示值均可由错误混淆矩阵精确重构。

根因是旧评价路径先按 padded batch 形状建立零初始化数组，再用不能排除这些有限零值的条件进入统计。padding 既没有真实残基，也没有合法甲基化标签，必须由真实长度/显式 mask 删除。附带的 data/historical_padding_batch16_reconstruction.csv 与 data/historical_padding_batch8_reconstruction.csv 保存了每个截图阈值的精确重构计数。

B.2 去 padding 后，Ser 真值修正仍然必要

只移除 padding、但继续使用旧 323 阳性标签时，已知序列 AUC 为 0.956，端到端 AUC 为 0.835；阈值 0.6 下，前者 Accuracy/Precision/Recall/F1 为 90.30%/96.83%/56.66%/71.48%，后者为 85.12%/89.60%/34.67%/50.00%。这些数值虽然已不受 padding 影响，但仍把 62 个本应为天然 Ser 的位点当作甲基阳性。

表 13 同一原始检查点在不同评价真值下的单体结果。阈值均为严格 $p > 0.6$ ；旧标签只用于敏感性比较。

真值版本	输入条件	AUC	Accuracy	Precision	Recall	F1
旧 323 阳性	已知序列	0.956	90.30%	96.83%	56.66%	71.48%
旧 323 阳性	端到端	0.835	85.12%	89.60%	34.67%	50.00%
Ser 修正 261 阳性	已知序列	0.900	86.18%	64.02%	46.36%	53.78%
Ser 修正 261 阳性	端到端	0.908	89.10%	88.80%	42.53%	57.51%

Ser 子集揭示了修正的影响：74 个 Ser 位点中只有 12 个为阳性；已知序列头在阈值 0.6 时把 74 个全部判为阳性，得到 $TP = 12$ 、 $FP = 62$ 、 $TN = 0$ 、 $FN = 0$ 。因此，旧标签会把这 62 个系统性假阳性错误奖励为真阳性。正文采用修正后的 261/1244 真值，既不隐藏模型在 Ser 上的缺陷，也不因错误标签虚增性能。

B.3 规划截图是指标清单，不是已完成数据

1. Model
 - 1.1. Fine-tuning based on methylated monomers
 - 1.2. Methylation classifier
2. Data
 - 2.1. Baker, 33 monomers with true structures
 - 2.2. Rosetta, 400+300 monomers with Rosetta-generated structures
 - 2.3. Complex, 17 multimers with true structures
3. Metrics
 - 3.1. Sequence
 - RAA (Recovery of amino acids) for fine-tuning module
 - AUC for methylation classifier
 - Accuracy for methylation classifier
 - RMC (Recovery of methylation classification) for methylation classifier
 - 3.2. Structure
 - RMSD_CA / RMSD_Backbone / RMSD_All
 - RMSD_CA_Methylation / RMSD_Backbone_Methylation / RMSD_All_Methylation
 - pLDDT / ipLDDT / pTM/ ipTM /pAE
 - BSR (Binding site ratio)
 - Success (ratio of peptides with lower energy than the native structure)
 - Stability (ratio of complexes with lower energy than the native structure)
 - Designability (RMSD < 2Å)
 - Diversity (structural dissimilarity among designed peptides, 1-TMScore)
 - 3.3. Membrane permeability

图9 尚哥提出的数据与指标规划截图。它定义了希望覆盖的项目，但不等于每项已经有原始结果；实际可用性逐项列于附录A。

截图中的“Baker, 33 monomers”、“Rosetta, 400+300 monomers”与冻结文件不一致。逐一审计 751 个原始 PDB 后，751/751 均含理论模型和 Rosetta 生成标记；406 个 Me_ 对应 Rosetta-2023，345 个 pdb_ 对应 Rosetta-2025。仓库、共享工作区与附件中均未找到可验证的 Baker 33 实验结构目录或清单。因此，本文采用“751 个 Rosetta 理论结构、600/151 划分”的可验证表述，不把规划截图冒充数据证据。

另有历史 V12 工作流的单体结构比较文件，但其检查点、结构队列和评价流程均不属于本文冻结的 V28 对象。为防止张冠李戴，本稿不移植其中任何数值；V28 单体结构指标仍明确标记为未计算。

C 联合RMSD低于5 Å的101条候选清单

表 14 逐条列出六个非3AV复合物中同时满足全复合物CA RMSD < 5 Å且最佳正向循环肽CA RMSD < 5 Å的101条候选。这些候选均来自正文定义的476条保留设计，并沿用“一次全复合物叠合、完整末链 CA 配对、最佳正向循环移位、不反向、不进行肽链二次拟合”的联合RMSD口径。“类别”列进一步标出其中16条联合 < 3 Å 候选；其余85条位于 [3, 5) Å 类别。序列大小写保持原始输出，小写残基表示严格 $p > 0.6$ 规则保存的预测甲基化标记，甲基化位点使用1基编号。

可复核的机器可读文件同时随稿提供：本表101条的完整记录位于 data/Pass_LT5_101.csv，其中16条联合 < 3 Å 候选另存于 data/Pass_LT3_16.csv；包含通过与未通过候选、各审计门控字段及两种 RMSD 的完整476条分析表位于 data/Candidates_476.csv。因此，本附录是便于人工阅读的通过清单，完整统计复算应以476条CSV为准。

表 14 六个非 3AV 复合物中联合 RMSD 低于 5 Å 的 101 条候选

编号	靶点	设计序列 (小写为甲基化)	甲基化位点	全复合物CA RMSD (Å)	循环肽CA RMSD (Å)	类别
1	1SFI	RCCrGNCGQCQFGG	4	0.536	2.818	< 3
2	1SFI	RCGrGcCrQGcNGG	4,6,8,11	0.562	3.693	3- < 5
3	1SFI	RCGrCQNGQCrNGG	4,11	1.120	3.840	3- < 5
4	1SFI	RrGrGrCGQCQFMQ	2,4,6	1.483	3.859	3- < 5
5	1SFI	CCGrGrCrQGrGGR	4,6,8,11	0.572	3.967	3- < 5
6	1SFI	RCGrQQCrKGcQMC	4,8,11	0.817	4.217	3- < 5
7	1SFI	RCGrGQCrKGrNGC	4,8,11	0.242	4.252	3- < 5
8	1SFI	RrrrGQCrQCNRDG	2,3,4,8	1.805	4.276	3- < 5
9	1SFI	RQYrGKGrQGrRMG	4,8,11	0.221	4.414	3- < 5
10	1SFI	RGGrCcCGGGNQMG	4,6	1.068	4.468	3- < 5
11	1SFI	RCHrCNGCQCrQGC	4,11	0.576	4.523	3- < 5
12	1SFI	RrGcCrCrKGKFDG	2,4,6,8	0.632	4.532	3- < 5
13	1SFI	RCGrGQCrKGrQDG	4,8,11	0.563	4.612	3- < 5
14	1SFI	RCGrGrCrQCrQMC	4,6,8,11	0.970	4.626	3- < 5
15	1SFI	CCrrrGCrKCNNNG	3,4,5,8	0.219	4.753	3- < 5
16	1SFI	RrGrGrCGQCcQMG	2,4,6,11	1.854	4.756	3- < 5
17	1SFI	RCrrrNNGGCrQGG	3,4,5,11	0.467	4.763	3- < 5
18	1SFI	CCYrCrCrKGrFDG	4,6,8,11	0.228	4.776	3- < 5
19	1SFI	RCGQGQCrQCrRDG	8,11	0.561	4.918	3- < 5
20	3P8F	CrrrGrQGKGrRGC	2,3,4,6,11	0.300	2.075	< 3
21	3P8F	GrGrGcCCQGrCMR	2,4,6,11	0.995	2.713	< 3
22	3P8F	GrrrCrCGQCrNMG	2,3,4,6,11	0.559	3.255	3- < 5
23	3P8F	CrhQrGCRrCQCGN	2,3,5,9	0.277	3.523	3- < 5
24	3P8F	CCGrrQCRQCrCRC	4,5,11	0.311	3.807	3- < 5
25	3P8F	RCrrGKCGQGrGCG	3,4,11	1.063	3.847	3- < 5
26	3P8F	RrrrrGCGQCrCGG	2,3,4,5,11	1.556	3.854	3- < 5

续下页

表 14 (续)

编号	靶点	设计序列 (小写为甲基化)	甲基化位点	全复合物CA RMSD (Å)	循环肽CA RMSD (Å)	类别
27	3P8F	RCrrrrGGQCrCMN	3,4,5,6,11	0.648	3.862	3- < 5
28	3P8F	RrKrGQCRQGcrRG	2,4,11,12	0.522	3.965	3- < 5
29	3P8F	RrrrGNCCKCrCDG	2,3,4,11	1.599	4.081	3- < 5
30	3P8F	RrrrGNCGKCrRRG	2,3,4,11	1.708	4.303	3- < 5
31	3P8F	QrrrGQCGFCrQMG	2,3,4,11	1.456	4.356	3- < 5
32	3P8F	RrhrCKCCrCrCMG	2,3,4,9,11	0.291	4.363	3- < 5
33	3P8F	RCGrGGCRQCrRCC	4,11	1.002	4.449	3- < 5
34	3P8F	RrrrGKCGQGrCMG	2,3,4,11	1.105	4.496	3- < 5
35	3P8F	GrGrGNCRQCrFMG	2,4,11	0.405	4.668	3- < 5
36	3P8F	RCrrrNCGQCrQDG	3,4,5,11	1.323	4.757	3- < 5
37	3P8F	CrrrGQCGQCrrMG	2,3,4,11,12	1.266	4.791	3- < 5
38	3P8F	RrrrQNCGQGrCMG	2,3,4,11	0.289	4.883	3- < 5
39	3P8F	RCGrGGCGNCrCGG	4,11	1.048	4.921	3- < 5
40	3WNE	GrKWNC	2	0.933	1.459	< 3
41	3WNE	GrGKFG	2	0.904	2.915	< 3
42	3WNE	GrGWQG	2	0.904	2.946	< 3
43	3WNE	GrGKGG	2	0.912	3.407	3- < 5
44	3WNE	GrNWRG	2	1.041	3.868	3- < 5
45	3ZGC	rEGGQNR	1	0.973	2.076	< 3
46	3ZGC	NrGGGQR	2	1.488	2.231	< 3
47	3ZGC	rrGGLGR	1,2	0.988	3.103	3- < 5
48	3ZGC	rrNGGGR	1,2	0.968	3.233	3- < 5
49	3ZGC	cGGGQDR	1	1.589	3.516	3- < 5
50	3ZGC	rGcGQGR	1,3	1.600	3.759	3- < 5
51	3ZGC	EcGQGMR	2	1.194	3.769	3- < 5
52	3ZGC	cCGGGNR	1	1.476	4.100	3- < 5
53	3ZGC	rGGGNLR	1	2.226	4.123	3- < 5
54	3ZGC	rrGGQDR	1,2	0.919	4.129	3- < 5
55	3ZGC	rGGGQGR	1	2.535	4.262	3- < 5

续下页

表 14 (续)

编号	靶点	设计序列 (小写为甲基化)	甲基化位点	全复合物CA RMSD (Å)	循环肽CA RMSD (Å)	类别
56	3ZGC	GrGGNQQR	2	1.847	4.281	3- < 5
57	3ZGC	rGGGGMR	1	2.742	4.367	3- < 5
58	3ZGC	cGGGQQR	1	2.443	4.370	3- < 5
59	3ZGC	rGGGQFR	1	2.337	4.454	3- < 5
60	3ZGC	cGGGGDR	1	2.344	4.456	3- < 5
61	3ZGC	cGGGQGR	1	2.284	4.469	3- < 5
62	3ZGC	rGGGGDR	1	1.651	4.618	3- < 5
63	3ZGC	cGGGGLR	1	2.967	4.651	3- < 5
64	3ZGC	rGDGGGR	1	1.801	4.686	3- < 5
65	3ZGC	rGGGQCR	1	2.553	4.750	3- < 5
66	3ZGC	cGGGKGR	1	2.274	4.767	3- < 5
67	3ZGC	rGGGQMR	1	2.744	4.898	3- < 5
68	4K1E	rcrrrQCrQGNCDR	1,2,3,4,5,8	0.900	1.916	< 3
69	4K1E	rcrrCrCrFGQCMR	1,2,3,4,6,8	0.637	2.157	< 3
70	4K1E	rcCrGrQrNGERLR	1,2,4,6,8	0.821	2.330	< 3
71	4K1E	rcCrrrQrQCQCDR	1,2,4,5,6,8	0.694	2.596	< 3
72	4K1E	rcrrGrCrQGhCLR	1,2,3,4,6,8,11	0.680	2.801	< 3
73	4K1E	CcCrrrRrQCrRLC	2,4,5,6,8,11	0.659	2.960	< 3
74	4K1E	CcGrCQCrEGFRDR	2,4,8	0.920	3.273	3- < 5
75	4K1E	rcrrrcCrFGQCDR	1,2,3,4,5,6,8	0.676	3.338	3- < 5
76	4K1E	rcrrCrRrQGcCWR	1,2,3,4,6,8,11	0.644	3.368	3- < 5
77	4K1E	rcQrrrGrQCQCDR	1,2,4,5,6,8	0.646	3.511	3- < 5
78	4K1E	rrGrGrCrFCLRGR	1,2,4,6,8	1.221	3.661	3- < 5
79	4K1E	rrrrGNQrQGQCMC	1,2,3,4,8	0.690	3.672	3- < 5
80	4K1E	rcrrCrQrrCQCMR	1,2,3,4,6,8,9	0.665	3.714	3- < 5
81	4K1E	rrrrCrCrRCQCMR	1,2,3,4,6,8	0.697	3.818	3- < 5
82	4K1E	rcrrrrCrQCQRDR	1,2,3,4,5,6,8	1.432	3.950	3- < 5
83	4K1E	rcCrrGQrrCQrDR	1,2,4,5,8,9,12	0.691	4.045	3- < 5
84	4K1E	rcNrrrCrQGQCDR	1,2,4,5,6,8	1.627	4.420	3- < 5

续下页

表 14 (续)

编号	靶点	设计序列 (小写为甲基化)	甲基化位点	全复合物CA RMSD (Å)	循环肽CA RMSD (Å)	类别
85	4K1E	rcKrrrCrCCLNWR	1,2,4,5,6,8	0.679	4.464	3- < 5
86	4K1E	rcCrGrCrQCNCDR	1,2,4,6,8	0.761	4.526	3- < 5
87	4K1E	rQrrGrCrKCNCDR	1,3,4,6,8	1.878	4.594	3- < 5
88	4K1E	rQCrGrCrQGFrDR	1,4,6,8,12	0.774	4.694	3- < 5
89	4K1E	rcGrCrCrQCQCMR	1,2,4,6,8	0.763	4.751	3- < 5
90	4K1E	rcrrGrCrFCQCGC	1,2,3,4,6,8	1.156	4.927	3- < 5
91	4K1E	rcCrCrNrQGECDR	1,2,4,6,8	1.094	4.970	3- < 5
92	4KEL	RcrrGNCrQGFCDR	2,3,4,8	0.654	2.379	< 3
93	4KEL	CcCrCNQrFGQRDR	2,4,8	1.188	2.477	< 3
94	4KEL	RcrrGrCWFCQRGR	2,3,4,6	0.988	3.421	3- < 5
95	4KEL	RrGrrrRrQGrRDR	2,4,5,6,8,11	0.695	4.174	3- < 5
96	4KEL	RcrrrQCrQGrCLR	2,3,4,5,8,11	0.657	4.267	3- < 5
97	4KEL	RrrrCQCQrGLCGR	2,3,4,9	0.666	4.367	3- < 5
98	4KEL	RcrKGrNrQGQCDDR	2,3,6,8	1.426	4.595	3- < 5
99	4KEL	RcCrGQNrQGQCGR	2,4,8	1.061	4.715	3- < 5
100	4KEL	CGrrGrCrQGrCGR	3,4,6,8,11	1.545	4.871	3- < 5
101	4KEL	RcrrrrCrFCrRDR	2,3,4,5,6,8,11	0.679	4.984	3- < 5

D 可复现性、文件索引与使用方法

D.1 本稿如何生成

本稿采用“复用已生成文件、不重新跑上游模型”的冻结策略。素材脚本只完成确定性的文件复制、CSV 导出、历史截图计数重构和汇总图生成；不会载入检查点，也不会调用结构预测、通透性模型或 PyRosetta。脚本入口见 `scripts/prepare_paper_assets.py`。论文中的每项数值必须回到 `data/`、`supplementary/` 或源清单。

表 16 交付目录索引。

路径	内容
<code>main.tex, main.pdf</code>	中文 LaTeX 源稿与已编译 PDF
<code>sections/</code>	正文和附录各章节
<code>figures/</code>	6 组论文图，提供 PDF/PNG/SVG
<code>data/</code>	主表 CSV、476 条审计、101/16 条通过名单及探索性结果
<code>tables/</code>	101 条联合 $\text{RMSD} < 5 \text{ \AA}$ 候选的 LaTeX 表格行
<code>supplementary/</code>	两个 Excel 工作簿、历史阈值截图与指标提纲截图
<code>fonts/</code>	中文子集字体、原版权声明、修改记录及 SIL OFL 1.1 许可证
<code>SOURCE_MANIFEST.json</code>	上游关键文件路径、字节数和 SHA-256
<code>scripts/</code>	素材整理脚本与 751 个 PDB 来源审计脚本
<code>requirements-assets.txt</code>	更新论文素材所需的固定 Python 依赖版本
<code>build.ps1, build.sh</code>	Windows PowerShell 与 Linux/macOS 构建入口

D.2 冻结标识与检查项

- 模型文件: `frankenstein_v28.pt`;
- 模型 SHA-256 (完整值):
`bab7b8a010114fc52c749fab1914d9d8ae561ddca45d6d7a0fbec3f9f5ac5b2e`;
- 仓库: `DCarchimonde/proteinmpnn-clean-v28`;
- 基线提交: `c9718e2a433a51f187606676dfedd11eeb6fc8a5`;
- 论文分支: `paper/task1-original-v28-cn-2026-08-21`;
- 单体主分母: 151 条、1505 位点、261 阳性、1244 阴性;
- 六复合物主分母: 544 条原始, 476 条甲基保留, 476 条 RMSD 成功匹配;
- 17 靶点 best85: 85/85 结构映射; 置信度 COMMENT 字段仅 37/85;
- 所有概率门均为严格 > 0.6 , 所有 RMSD 门均为严格 $< d$;
- 101 条 $< 5 \text{ \AA}$ 与 16 条 $< 3 \text{ \AA}$ 名单均可由 `Candidates_476.csv` 重新筛选得到。

D.3 本地编译

仓库已经提交编译后的 `main.pdf`, 仅阅读不需要安装 LaTeX。若要改稿重编译, 在论文目录执行:

```
# Windows PowerShell
.\build.ps1
```

```
# Linux/macOS
bash build.sh
```

构建脚本使用 XeLaTeX、BibTeX、XeLaTeX 两遍，以解析中文、目录、交叉引用与文献。中文正文使用仓库内随稿提供的子集字体，不依赖系统安装 ctex 或中文字体。若上游数据有意更新，应先运行 `python scripts/prepare_paper_assets.py`，随后重编译；维护者工作区中的上游文件不存在时，该脚本复用随稿的冻结副本。任何更新都应同时修改版本、日期与 `SOURCE_MANIFEST.json`。重新扫描751个原始 PDB 则需另行检出源清单中冻结的历史仓库提交。

D.4 解释规则

复核本稿时应始终保留以下边界：条件通过率不等于原始端到端产率；肽自拟合 RMSD 不等于结合姿态；B-factor/pLDDT 不等于能量；fixed-pose Rosetta 分数不等于结合自由能；oracle best-of-N 不等于盲生成性能；未计算和不可定义不等于零。这些规则也是后续 V8/V9 比较必须沿用的共同基线。

参考文献

- [1] Justas Dauparas, Ivan Anishchenko, Nathaniel Bennett, Hua Bai, Robert J. Ragotte, Lukas F. Milles, Basile I. M. Wicky, Alexis Courbet, Rob J. de Haas, Neville Bethel, et al. Robust deep learning-based protein sequence design using proteinmpnn. *Science*, 378(6615):49–56, 2022.
- [2] Yang Zhang and Jeffrey Skolnick. Scoring function for automated assessment of protein structure template quality. *Proteins: Structure, Function, and Bioinformatics*, 57(4):702–710, 2004.
- [3] John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Zidek, Anna Potapenko, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 596:583–589, 2021.
- [4] Zeming Lin, Halil Akin, Roshan Rao, Brian Hie, Zhongkai Zhu, Wenting Lu, Nikita Smetanin, Robert Verkuil, Ori Kabeli, Yaniv Shmueli, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 379(6637):1123–1130, 2023.
- [5] Sidhartha Chaudhury, Sergey Lyskov, and Jeffrey J. Gray. Pyrosetta: a script-based interface for implementing molecular modeling algorithms using rosetta. *Bioinformatics*, 26(5):689–691, 2010.
- [6] Andrew Leaver-Fay, Michael Tyka, Steven M. Lewis, Oliver F. Lange, James Thompson, Ron Jacak, Kristian Kaufman, P. Douglas Renfrew, Colin A. Smith, Will Sheffler, et al. Rosetta3: an object-oriented software suite for the simulation and design of macromolecules. *Methods in Enzymology*, 487:545–574, 2011.